유튜브 강의로
단 2시간 만에 완벽 정복

IT 전문가가 직접 정리한

ADsP
완벽대비 요약노트

시험에 나오는 **핵심내용**
+ 저절로 외워지는 쉬운 **암기법**

아답터
IT의 답을 터득하다

- 아답터(민 기술사)

개정 버전 : 2025.01.10



ADsP
완벽대비 요약노트

이 자료의 내용은 아답터교육의 소중한 자산이며, 특정 단체나 커뮤니티, 학원에서의 허가 받지 않은 사용 및 공유 시 법적 처벌을 받을 수 있습니다.

- ADsP 과목 및 내용

데이터 이해	데이터의 이해	데이터와 정보
		데이터베이스의 정의와 특징
		데이터베이스 활용
	데이터의 가치와 미래	빅데이터의 이해
		빅데이터의 가치와 영향
		비즈니스 모델
		위기 요인과 통제 방안
		미래의 빅데이터
	가치 창조를 위한 데이터 사이언스와 전략 인사이트	빅데이터분석과 전략 인사이트
		전략 인사이트 도출을 위한 필요 역량
		빅데이터 그리고 데이터 사이언스의 미래

데이터분석 기획	데이터분석 기획의 이해	분석 기획 방향성 도출
		분석 방법론
		분석 과제 발굴
		분석 프로젝트 관리 방안
	분석 마스터 플랜	마스터 플랜 수립
		분석 거버넌스 체계 수립

데이터분석	R기초와 데이터 마트	R기초
		데이터 마트
		결측값 처리와 이상값 검색
	통계분석	통계학 개론
		기초 통계분석
		다변량 분석
		시계열 예측
	정형 데이터 마이닝	데이터 마이닝 개요
		분류분석(Classification)
		군집분석(Clustering)
		연관분석(Association Analysis)

1과목 – 데이터 이해

1. 데이터의 이해

- 데이터와 정보

● **데이터**

- 데이터 : 있는 그대로의 객관적 사실, 가공되지 않은 상태 (주문수량)
- 정보 : 데이터로부터 가공된 자료 (베스트셀러)

● **데이터의 유형**

(1) 정성적, 정량적

- 정성적 데이터 : 자료의 특징을 풀어 설명 - 언어, 문자 (기상특보, 주관식 설문 응답)
- 정량적 데이터 : 자료를 수치화 - 수치, 기호 (온도, 풍속)

(2) 정형, 반정형, 비정형

- 정형 데이터 : 정보 형태가 정해짐 (관계형DB, 엑셀-스프레드시트, CSV)
- 반정형 데이터 : 데이터를 설명하는 메타데이터를 포함 (로그, HTML, XML, JSON)
- 비정형 데이터 : 형태가 정해지지 않음 (SNS, 유튜브, 음원)

● **암묵지, 형식지간 상호작용**

- 암묵지 : 개인에게 습득되고 겉으로 드러나지 않음
- 형식지 : 문서, 매뉴얼 등의 형상화된 지식

1) 공통화 : 암묵지 지식을 다른 사람에게 알려줌
2) 표출화 : 암묵지 지식을 매뉴얼이나 문서로 전환
3) 연결화 : 교재, 매뉴얼에 새로운 지식 추가
4) 내면화 : 만들어진 교재, 매뉴얼에서 다른 사람의 암묵지를 터득

☞ **'공표연내'**

● **DIKW 피라미드**

(1) 데이터(Data) : 있는 그대로의 사실 (A대리점 핸드폰 100만원, B대리점 핸드폰 200만원)
(2) 정보(Information) : Data를 통해 패턴 인식 (A대리점이 핸드폰이 싸다)
(3) 지식(Knowledge) : 패턴을 통해 예측 (A에서 핸드폰을 사면 이득을 보겠다)
(4) 지혜(Wisdom) : 창의적인 산물 (A대리점의 다른 기기들도 B대리점보다 저렴 할 것이다)

● **데이터 단위**

- KB < MB < GB < TB < PB < EB < ZB < YB (Peta < Exa < Zetta < Yotta)

☞ **'패지요!'**

- 데이터베이스의 정의와 특징

● 데이터베이스의 정의

(1) DB : 일정 구조에 맞게 조직화된 데이터의 집합

- 스키마 : DB의 구조와 제약조건에 관한 전반적 명세
- 인스턴스 : 정의된 스키마에 따라 저장된 값

(2) DBMS : DB를 관리, 접근 환경 제공하는 소프트웨어

1) 관계형 DBMS : 테이블(표)로 정리
(오라클, MSSQL, MYSQL, MARIA DB)

2) 객체지향 DBMS : 정보를 객체형태로 정리

3) NoSQL DBMS : 비정형 데이터를 저장하고 처리
(HBASE, Mongo DB, Dynamo DB, Cassandra)

(3) SQL : 데이터 베이스에 접근할 수 있는 하부언어

- 정의언어(DDL) : CREATE, ALTER, DROP
- 조작언어(DML) : SELECT, INSERT, DELETE, UPDATE
- 제어언어(DCL) : COMMIT, ROLLBACK, GRANT, REVOKE

● 데이터베이스의 특징

(1) 공용 데이터 : 여러 사용자가 다른 목적으로 데이터 공동 이용

(2) 통합된 데이터 : 동일한 데이터 중복되어 있지 않음

(3) 저장된 데이터 : 저장매체에 저장

(4) 변화되는 데이터 : 새로운 데이터 추가,수정,삭제에도 현재의 정확한 데이터 유지

☞ **'공통저변'**

● 데이터베이스의 구성요소

- 메타데이터 : 데이터를 설명하는 데이터
- 인덱스 : 정렬, 탐색을 위한 데이터의 이름

● 데이터베이스 설계 절차

(1) 요구조건 분석

(2) 개념적 설계 : 개념적 스키마 생성

(3) 논리적 설계 : 개념적 ERD를 활용한 논리적 모델링

(4) 물리적 설계 : 저장 구조 설계

☞ **'개논물'**

- 데이터베이스 활용

● 기업 활용 데이터베이스

- OLTP : 데이터를 수시로 갱신 (거래단위)
- OLAP : 다차원 데이터를 대화식으로 분석
- CRM : 고객과 관련 자료 분석, 마케팅 활용
- SCM : 공급망 연결 최적화
- ERP : 기업 경영 자원을 효율화
- RTE : 최신 정보로 빠른 의사결정 지원
- BI : 기업 보유 데이터 정리,분석하여 리포트 중심 도구
- BA : 통계 기반 비즈니스 통찰력
- Block Chain : 네트워크 참여한 모든 사용자가 정보를 분산, 저장
- KMS : 기업의 모든 지식을 포함

● Data Ware House(DW)

(1) 특징

- 주제지향성 : 분석목적 설정이 중요
- 데이터 통합 : 일관화 된 형식으로 저장
- 시계열성 : 히스토리를 가진 데이터
- 비휘발성 : 읽기전용 - 수시로 변하지 않음

(2) 구성요소

- ETL(Extraction, Transformation, Load) : DW와 DM 등의 DB 시스템에 데이터 적재
- ODS(Operational Data Store) : 다양한 DBMS에서 추출한 데이터를 임시 저장

● Data Lake

- 비정형 데이터를 저장하며 하둡과 연계하여 처리
- 하둡 : 병렬처리 오픈소스 프레임워크
  1) HDFS : 분산형 파일 저장 시스템
  2) MapReduce : 분산된 데이터를 병렬로 처리

2. 데이터의 가치와 미래

- 빅데이터의 이해

● 빅데이터 출현 배경

- 인터넷 확산, 스마트폰 보급, 클라우딩 컴퓨팅으로 인한 경제성 확보, 저장매체 가격하락, 하둡을 활용한 분산 컴퓨팅, 비정형 데이터 확산

● **빅데이터의 3V (가트너 정의)**

(1) Volume(규모) : 데이터 양 증가 (구글 번역 서비스)

(2) Variety(다양성) : 데이터 유형 증가

(3) Velocity(속도) : 데이터 생성, 처리 속도 증가

(4) 그 외 5V에 포함되는 요소

- Value(가치) / Veracity(신뢰성) / 정확성(Validity) / 휘발성(Volatility)

● **빅데이터에 대한 비유**

(1) 산업혁명의 석탄, 철 : 산업혁명에서의 석탄, 철 역할

(2) 원유 : 정보제공으로 생산성 향상

(3) 렌즈 : 현미경이 생물학 발전 영향, 산업 전반에 영향 (구글 Ngram Viewer)

(4) 플랫폼 : 공동 활용 목적으로 구축된 구조물, 써드파티 비즈니스에 활용 (페이스북)

* 써드파티 : 원천기술을 활용한 파생상품 만드는 회사

● **빅데이터가 만들어내는 변화**

(1) 표본조사 → 전수조사

(2) 사전처리 → 사후처리

(3) 질 → 양

(4) 인과관계 → 상관관계

☞ **'전후양상'**

- 빅데이터의 가치와 영향

● **빅데이터 가치 산정이 어려운 이유**

(1) 특정 데이터를 언제, 어디서, 누가 활용할지 알 수 없음

(2) 기존에 가치 없는 데이터도 새로운 분석기법으로 가치를 창출

- 비즈니스 모델

● **빅데이터 활용 위한 3대 요소**

- 인력, 자원(데이터), 기술

☞ **'인자기'**

● **빅데이터의 주요 분석기법**

- 회귀분석 : 독립변수와 종속변수 관계, X가 Y에 어떤 영향을 미치는가?
  (고객만족도가 높은 사람은 재방문할 확률 높은가?)
- 유형분석 : A와 B는 어디에 속하는 범주 (같은 패턴을 보이는 동물)
- 연관규칙 : 여러 요소들 간의 규칙 상관관계 존재 (마트에서 치킨과 맥주를 같이 사는 관계)
- 유전자 알고리즘 : 최적화 필요한 문제의 해결책
  (택배차량 어떻게 배치, 최대 시청률 얻으려면 어떤 프로그램을 어떤 시간대에 방송?)
- 기계학습 : 훈련 데이터로부터 컴퓨터가 학습하고 미래를 예측 (넷플릭스 영화 추천 시스템)
- 감정분석 : 감정(긍정/부정) 분석 (후기를 바탕으로 원하는 것 발견)
- 소셜 네트워크 분석 : 사람간의 관계 SNS상 사용자들 관계 속 영향력 높은 사람 찾기)

- 위기 요인과 통제 방안

● **위기 요인과 통제방안**

(1) 사생활 침해 : SNS 올린 데이터가 사생활 침해
→ 제공자에서 사용자 책임으로 전환

(2) 책임 원칙 훼손 : 범죄 예측 프로그램으로 예측하여 체포하는 문제
→ 결과에 대해서만 책임

(3) 데이터의 오용 : 분석 결과가 항상 옳은 것은 아님
→ 알고리즘을 해석가능한 알고리즈미스트 필요
* 알고리즈미스트 : 부당하게 피해가 발생한 사람들을 구제하는 전문인력

● **개인정보 비식별화**

(1) 데이터 마스킹 : 홍길동 → 홍XX

(2) 가명처리 : 홍길동 → 임꺽정

(3) 총계처리 : A ; 165, B : 170, C : 175 → 합 : 510, 평균 : 170

(4) 범주화 : 홍길동 35세 → 홍길동 30 ~ 40세

- 미래의 빅데이터

● **미래의 빅데이터**

(1) 서비타이제이션(Servitization) : 서비스와 제품의 결합, 기존-신규 서비스의 결합

(2) 마이데이터 : 자신의 신용 정보를 다른 제3자에게 제공하여 서비스를 제공받음

(3) 딥러닝 : 사람의 뇌 구조를 모방한 인공신경망을 활용하는 기계학습(머신러닝) 기법

2. 가치 창조를 위한 데이터 사이언스와 전략 인사이트

- 빅데이터분석과 전략 인사이트

● **전략 인사이트**

- 집중과 선택 (많은 데이터나 다양한 대상에 분산보다는 현재 분석에 집중)
- 업계 상황만 보지 말고 더 넓은 시야에서 봐야함
- 경영진의 전략적 인사이트에 기여

☞ 조직이 분석을 배우는 상태이거나 특정 문제의 범위를 해결할 때는 집중과 선택

☞ 사업 상황들을 확인할 때는 넓은 시야

● **데이터 사이언스**

- 데이터와 관련된 모든 분야의 전문지식을 종합한 학문
- 정형/비정형 데이터를 막론하고 데이터를 분석 (총체적 접근법)

● **데이터 사이언스 핵심 구성요소**

(1) Analytics : 이론적 지식

(2) IT : 프로그래밍적 지식

(3) 비즈니스 분석 : 비즈니스적 능력

☞ **'AI비'**

- 전략 인사이트 도출을 위한 필요 역량

● **데이터 사이언티스트의 필요역량**

(1) 하드 스킬(Hard Skill) : 이론적 지식(수학, 통계학, 가설검정 등), 가트너 제시 역량에 미포함

(2) 소프트 스킬(Soft Skill) : 스토리텔링, 리더십, 창의력, 분석 등

☞ 하드스킬은 이과적, 소프트 스킬은 문과적인 느낌

- 빅데이터 그리고 데이터 사이언스의 미래

● **빅데이터 가치 패러다임 변화**

- Digitalization → Connection → Agency

(1) Digitalization : 아날로그 세상을 디지털화

(2) Connection : 디지털화된 정보들의 연결

(3) Agency : 연결을 효과적으로 관리

☞ **'DigitalCA메라'**

2과목 – 데이터분석 기획

1. 데이터분석 기획의 이해

- 분석 기획 방향성 도출

● **분석 대상과 방법**

대상 / 방법	Known	UnKnown
Known	최적화 (Optimization)	통찰 (Insight)
Un-Known	솔루션 (Solution)	발견 (Discovery)

● **분석 기획 방안**

	과제 중심적 접근	장기적 마스터 플랜
목적	빠르게 해결	지속적 분석 원인 해결
1차 목표	Speed & Test	Accuracy & Deploy
과제유형	Quick & Win	Long Term View
접근방식	Problem Solving	Problem Definition

● **분석 기획시 고려사항**

(1) 가용 데이터 : 분석의 기본이 되는 데이터 확보 및 파악

(2) 적절한 유스케이스 탐색 : 기존에 잘 구현 되어있는 유사 시나리오 활용

(3) 장애요소에 대한 사전계획 수립 : 조직의 역량으로 내제화

● **의사결정을 가로막는 요소**

- 고정 관념, 편향된 생각
- 프레이밍 효과 : 동일 상황임에도 개인의 판단, 결정이 달라짐

- 분석 방법론

● 분석 방법론의 구성요소

- 절차, 방법, 도구와 기법, 템플릿과 산출물

● 분석 방법론 모델

(1) 폭포수 모델 : 이전단계 완료되어야 다음 단계 진행 (Top-Down)

(2) 나선형 모델 : 여러 개발과정 거쳐 점진적으로 완성, 위험요소 제거 초점

(3) 프로토타입 모델 : 일부분(프로토타입)을 우선 개발하고 보완

(4) 애자일 : 일정한 주기를 가지고 프로토타입을 끊임없이 수정하여 고객의 Needs 반영

(5) 계층적 프로세스 모델 : 단계(Baseline으로 관리) → 태스크 → 스텝

● KDD 분석 방법론

- 데이터선택 → 전처리 → 변환 → 마이닝 → 결과 평가

1) 전처리 : 이상값, 잡음 식별 및 데이터 가공

2) 변환 : 변수 선택 및 차원축소

● Crisp-DM 분석 방법론

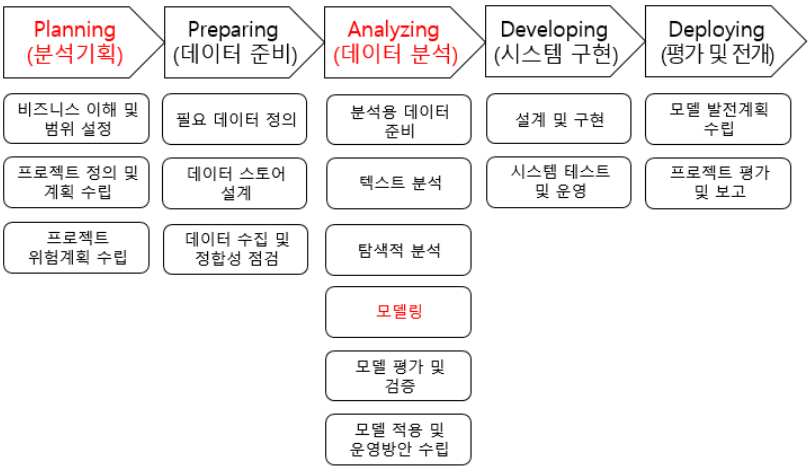
- 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개

☞ **'업데데이트모델평가전'**

1) 모델링 단계에서 모델 평가 수행하고 평가 과정 단계에서 모델 적용성 평가 수행

2) 평가 → 전개에서 위대한 실패 발생 가능

● 빅데이터 분석 방법론



1) 분석 기획
- 비즈니스 범위 설정 : SOW(Statement of Works) – 구조화된 프로젝트 정의서
- 위험 계획 수립 (회피, 전이, 완화, 수용)

☞ **'회전완수'**

2) 데이터 분석
- 추가적인 데이터 확보 필요 시, 데이터 준비 단계로 다시 진행

3) 데이터 분석 - 모델링
- 가설 설정 통해 통계 모델이나 기계학습을 이용한 분류, 예측 등의 모델을 만드는 과정
- 의사 코드 : 일반적인 언어로 프로그래밍 언어의 알고리즘을 유사한 형식으로 써 놓은 것

- 분석 과제 발굴

● 디자인 싱킹

- 사용자에 공감으로 시작해서 아이디어 발산/수렴 과정을 통한 피드백으로 발전하는 과정
- 공감하기 → 문제정의 → 아이디어 도출 → 프로토타입 → 테스트

● 하향식 접근 방법

- 문제가 주어지고 해답을 찾기 위해 진행
- 문제 탐색 → 문제 정의 → 해결방안 → 타당성 검토

(1) 문제탐색

1) 빠짐없이 문제를 도출하고 식별하며, 솔루션 초점 보다는 가치에 초점

2) 기존 시스템 개선하여 사용 가능하면 개선하여 활용

3) 비즈니스 모델 캔버스 단순화 측면 : 업무, 제품, 고객, 규제와 감사, 지원인프라

☞ **'지원인프라 업무** 중에 **고객**이 **제품**을 **규제와 감사** 했다.'

4) 관점
- 거시적 관점 : STEEP(사회, 기술, 경제, 환경, 정치)
- 경쟁자 확대 관점 : 대체자, 경쟁자, 신규 진입자
- 시장의 니즈 탐색 관점 : 고객, 채널, 영향자

5) 분석 유스 케이스
- 발굴한 분석 기회들을 구체적 과제로 만들기 전에 상세한 설명과 효과를 명시

(2) 타당성 검토
- 경제적 타당성 : 비용대비 편익 분석관점 접근
- 데이터 타당성 : 데이터 존재여부, 분석역량 이 필요
- 기술적 타당성 : 역량 확보 방안 사전에 수립

● **상향식 접근 방법**

- 문제 정의 자체가 어려울 때, 사물을 그대로 인식하는 What 관점
- 주로 비지도 학습

● **지도학습, 비지도학습**

(1) 지도 학습

- 정답이 있는 데이터를 학습
- 분류분석, 회귀분석, 의사결정트리, KNN, SVM

(2) 비지도 학습

- 정답이 없는 데이터를 학습
- 군집분석, 차원축소, 연관규칙분석

- 분석 프로젝트 관리 방안

● **분석 과제에서 고려해야할 5가지 요소**

- 데이터 크기, 속도, 데이터 복잡도, 분석 복잡도, 정확도/정밀도

* 정확도(Accuracy)와 정밀도(Precision)는 Trade-Off 관계 / 정확도와 복잡도도 Trade-Off관계

☞ 여기에서의 정확도와 정밀도는 3과목의 오분류표에서의 평가지표와는 다른 개념임

● **프로젝트 관리 지식 체계 10가지 영역**

- 통합, 범위, 시간(일정), 원가(비용), 품질, 인적자원, 의사소통, 리스크(위험), 조달, 이해관계자

☞ **'이범통**이 **의자**에서 **시원**한 **조리품**을 먹었다.'

2. 분석 마스터플랜

- 마스터 플랜 수립

● **우선순위 선정**

(1) 전략적 중요도 : 전략적 필요성, 시급성

(2) 실행 용이성 : 투자 용이성, 기술 용이성

● **ISP**

- 중장기 마스터 플랜을 수립하는 절차

● **ROI 관점**

(1) 시급성 관점 : 비즈니스 효과(Return) – Value

(2) 난이도 관점 : 투자비용 요소(Investment) – Volume, Variety, Velocity

(어려움) **난이도** (쉬움)	**1**	**2**
	3	**4**
	(현재) **시급성** (미래)	

- 시급성 중요시 : 3 → 4 → 2
- 난이도 중요시 : 3 → 1 → 2

☞ 3과 2는 앞 뒤로 고정하고 가운데만 변경

- 분석 거버넌스 체계 수립

● **분석 거버넌스 체계 구성요소**

- 조직, 프로세스, 시스템, 데이터, 분석관련 교육 및 마인드 육성체계

☞ **'시조프로마인드데'**

● **데이터 분석 수준 진단**

(1) 분석 준비도

1) 분석업무파악 : 사실 분석, 예측, 시뮬레이션, 최적화, 분석 업무 정기적 개선
2) 분석 인력 및 조직 : 분석전문가, 관리자, 조직, 경영진 이해
3) 분석기법 : 적합한 기법 사용, 분석기법 라이브러리/평가/개선
4) 분석데이터 : 데이터 관리, 외부데이터 활용, 기준데이터 관리(MDM)
5) 분석문화 : 의사결정, 회의에서 활용, 공유 및 협업 문화
6) IT 인프라 : 운영 시스템 통합, 환경

☞ **'IT문데기인파'**

(2) 분석 성숙도

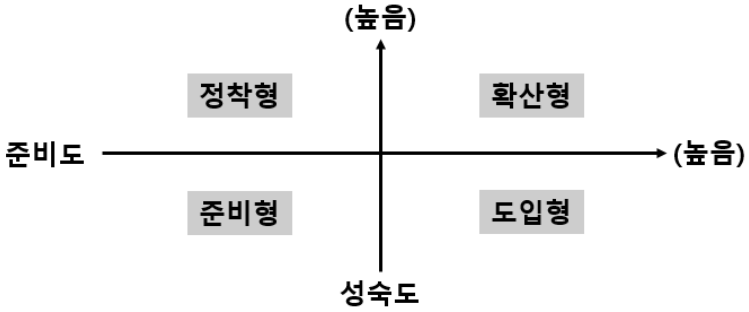
* CMMI 모델 기반 (1~5단계)

- 비즈니스 / 조직,역량 / IT 부문 관점으로 구분

1) 도입 : 환경, 시스템 구축
2) 활용 : 업무에 적용
3) 확산 : 전사 차원 관리, 공유
4) 최적화 : 혁신, 성과향상에 기여

☞ **'도활확최'**

● **데이터 분석 성숙도 모델**



1) 준비형 : 낮은 준비도, 낮은 성숙도
 - 데이터, 인력, 조직, 분석업무, 분석기법 적용 안되어 사전 준비 필요
2) 정착형 : 낮은 준비도, 높은 성숙도
 - 인력, 조직, 분석업무, 분석기법 등을 제한적으로 사용
3) 도입형 : 높은 준비도, 낮은 성숙도
 - 조직 및 인력 등 준비도는 높으나, 분석업무 및 기법 부족
4) 확산형 : 높은 준비도, 높은 성숙도
 - 6가지 분석 구성요소가 모두 갖추고 있으며, 지속적 확산이 가능

☞ **'도준정확'** 4사분면부터 시계방향(역순)으로 암기

● **분석 지원 인프라 방안 수립**

- 확장성을 고려한 플랫폼 구조 적용 (중앙집중적 관리)

(1) 분석 플랫폼 구성요소

1) 광의의 분석 플랫폼 : 분석 서비스 제공엔진, 분석 어플리케이션, 분석 서비스 API, 하드웨어
2) 협의의 분석 플랫폼 : 데이터 처리 프레임워크, 분석엔진, 분석 라이브러리

☞ 광의의 분석 플랫폼은 협의의 분석 플랫폼 요소들을 포함하는 개념

● **데이터 거버넌스**

(1) 데이터 거버넌스

1) 전사 차원에서 데이터 대해 표준화된 관리 체계 수립
2) 구성요소 : 원칙, 조직, 프로세스

☞ **'원조프'**

3) 중요 관리대상 : 마스터 데이터, 메타데이터, 데이터 사전 등
 - 마스터 데이터 : 자료 처리에 기준이 되는 자료
 - 메타데이터 : 다른 데이터를 설명해 주는 데이터
 - 데이터 사전 : DB에 저장된 정보를 요약

(2) 데이터 거버넌스 체계

1) 데이터 표준화 : 메타데이터 및 사전 구축

2) 데이터 관리 체계 : 효율성을 위함

3) 데이터 저장소 관리 : 저장소 구성

4) 표준화 활동 : 모니터링, 표준 개선 활동

● **빅데이터 거버넌스**

- 데이터 거버넌스 체계 + 빅데이터 효율적 관리, 데이터 최적화, 정보보호, 데이터 카테고리별 관리책임자 지정 등을 포함

● **조직 및 인력방안 수립 (DSCoE : 분석조직)**

- 집중 구조 : 독립적인 전담 조직 구성 (중복 업무 가능성 존재)
- 기능 구조 : 해당 부서에서 직접 분석 (DSCoE가 없음)
- 분산 구조 : 분석 조직 인력을 현업 부서에 배치

☞ **'집기분'**

3과목 – 데이터분석

1. R기초와 데이터 마트

- R기초

● **데이터 전처리**

- 데이터를 분석하기 위해 데이터를 가공하는 작업

(1) 요약변수 : 수집된 정보를 종합한 변수로서 재활용성이 높음 (1개월간 수입)

(2) 파생변수 : 의미를 부여한 변수, 논리적 타당성 필요 (고객구매등급)

● **R에서의 데이터 전처리 패키지**

(1) reshape : melt로 녹인 데이터를 cast로 재구조화

(2) sqldf : R에서 SQL을 활용하여 데이터프레임(DF)을 다룰 수 있게 해줌

(3) plyt : apply 함수 기반 데이터 처리

(4) data.table : 컬럼별 인덱스로 빠른 처리가 가능한 데이터 구조

- 데이터 마트

● **데이터 마트(DM)**

- 데이터 웨어 하우스의 한 분야로 특정 목적을 위해 사용 (소규모 데이터웨어하우스)

- 결측값과 이상값 검색

● **EDA (탐색적 자료 분석)**

- 데이터의 의미를 찾기 위해 통계, 시각화를 통해 파악
- EDA의 4가지 주제 : 저항성의 강조, 잔차 계산, 자료변수의 재표현, 그래프를 통한 현시성

☞ **'저잔재현'**

● **결측값**

- 존재하지 않는 데이터, null/NA로 표시, 의미 있는 데이터 일수도 있음

(1) 단순대치법 - 완전분석법

- 결측값 가지는 데이터 삭제
- complete.cases 함수로 FALSE 데이터에 결측값 제거

(2) 단순대치법 - 평균대치법

- 비조건부 평균 대치 : 단순평균으로 대치

- 조건부 평균 대치 : 회귀분석 활용

(3) 단순대치법 - 단순 확률 대치법

- 가까운 값으로 변경 (K-Nearest Neighbor을 주로 활용)
- Hot-Deck(현 연구 내 비슷한 성향으로 대체), Cold-Deck(외부출처에서 비슷한 성향으로 대체)

(4) 다중대치법

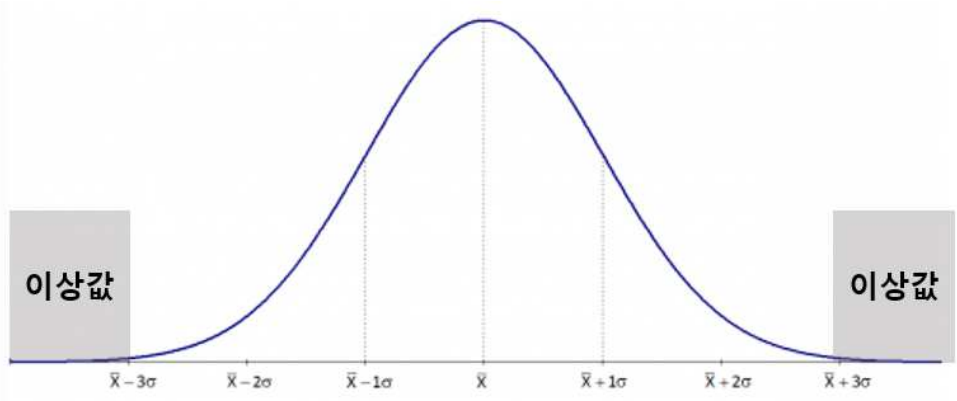
- 여러 번 대치 (대치 → 분석 → 결합)

● **이상값**

- 극단적으로 크거나 작은 값이며, 의미 있는 데이터 일수도 있음 (체중 3kg)
- 이상값을 항상 제거하는 것은 아님

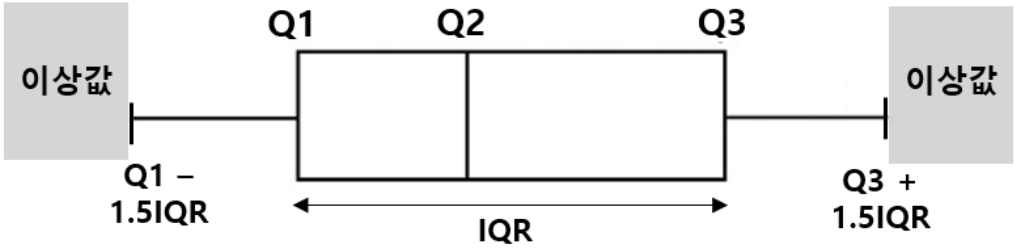
(1) ESD(Extreme Studentized Deviation)

- 평균으로부터 표준편차의 3배 넘어가는 데이터는 이상값으로 판단



(2) 사분위수

- Q1 – 1.5IQR보다 작거나, Q3 + 1.5IQR보다 크면 이상값으로 판단



2. 통계분석

- 통계학 개론

● **전수조사와 표본조사**

- 전수조사 : 전체를 다 조사, 시간과 비용 많이 소모
- 표본조사 : 일부만 추출하여 모집단을 분석

● **표본 추출 방법**

(1) 랜덤 추출법 : 무작위로 표본 추출

(2) 계통 추출법 : 번호 부여하여 일정 간격으로 추출

(3) 집락 추출법

- 여러 군집으로 나눈 뒤 군집을 선택하여 랜덤 추출
- 군집 내 이질적 특징, 군집 간 동질적 특징

(4) 층화 추출법

- 군집 내 동질적 특징, 군집 간 이질적 특징
- 같은 비율로 추출 시, 비례 층화 추출법

(5) 복원, 비복원 추출

- 복원 추출 : 추출되었던 데이터를 다시 포함시켜 표본 추출
- 비복원 추출 : 추출되었던 데이터는 제외하고 표본 추출

● **자료의 척도 구분**

(1) 질적 척도

- 명목척도 : 어느 집단에 속하는지 나타내는 자료 (대학교, 성별)
- 순서척도(서열척도) : 서열관계가 존재하는 자료 (학년, 순위)

(2) 양적 척도

- 등간척도(구간척도) : 구간 사이 간격이 의미가 있으며 덧셈과 뺄셈만 가능 (온도, 지수 등)
- 비율척도 : 절대적 기준 0이 존재하고 사칙연산 가능한 자료 (무게, 나이 등)

● **기초 통계량**

(1) 평균(기댓값) : 전체 합을 개수로 나눈 값

(2) 중앙값 : 자료를 크기 순으로 나열했을 때 가운데 값

(3) 최빈값 : 가장 빈번하게 등장하는 값

(4) 분산 : 자료들이 퍼져있는 정도 / 표준편차 : 분산의 제곱근 값

(5) 공분산 : 두 확률변수의 상관정도

- 공분산 = 0 : 상관이 전혀 없는 상태
- 공분산 > 0 : 양의 상관관계
- 공분산 < 0 : 음의 상관관계
- 최소, 최대값이 없어 강약 판단 불가

(6) 상관계수

- 상관정도를 -1 ~ 1값으로 표현
- 상관계수 = 1 : 정비례 관계
- 상관계수 = - 1: 반비례 관계

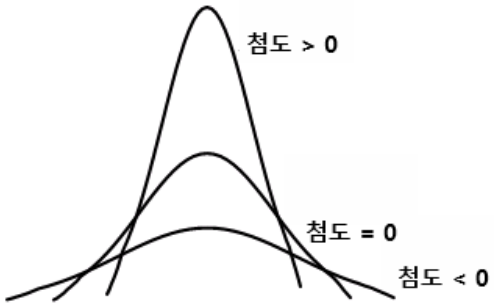
● **첨도와 왜도**

(1) 첨도 : 자료의 분포가 얼마나 뾰족한 지 나타내는 척도

- 첨도 = 0 : 정규 분포 형태

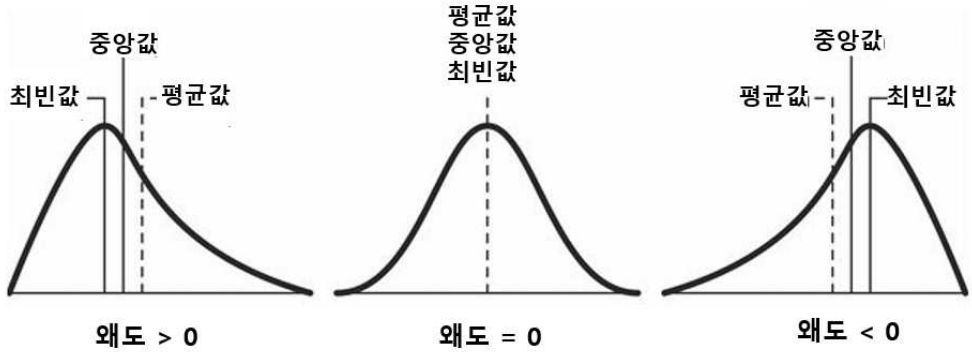
☞ 3을 기준으로 정규분포 형태를 판단하기도 함

- 값이 클수록 뾰족한 모양



(2) 왜도 : 자료 분포의 비대칭 정도 (0일 때 대칭)

- 왜도 < 0 : 최빈값 > 중앙값 > 평균값
- 왜도 > 0 : 최빈값 < 중앙값 < 평균값



☞ 평균값은 꼬리를 따라감

● **Summary함수 결과의 해석**

- 통계 요약 해석 Age Survived Min. : 0.17 0:266 1st Qu.:21.00 1:152 Median :27.00 Mean :30.27 3rd Qu.:39.00 Max. :76.00 NA's :86	1) Age 변수 - Mean, Median 등 존재 → 수치형 변수 - 25% 지점 : 21.00, 75% 지점 : 39.00 - Median < Mean → 왜도 > 0 - 결측치(NA's) 개수 : 86개 2) Survived 변수 - 집단의 빈도 수 → 범주형 변수

● 기초 확률 이론

(1) 조건부 확률 : 특정 사건 B가 발생했을 때 A가 발생할 확률

- $P(A|B) = P(A \cap B)/P(B)$ (백신을 맞았을 때 감기에 걸릴 확률)

(2) 독립사건 : A, B가 서로 영향을 주지 않는 사건 ($P(A|B) = P(A)$)

- $P(A \cap B) = P(A)P(B)$ (주사위 A가 3이 나왔을 때, 주사위 B가 3이 나올 확률)

(3) 배반사건 : A, B가 서로 동시에 일어나지 않는 사건

- $P(A \cap B) = \emptyset$ (동전을 던졌을 때 앞면과 뒷면이 동시에 나올 확률)

● 확률분포

- 확률변수가 특정한 값을 가질 확률을 나타내는 함수

(1) 이산 확률분포 : 값을 셀 수 있는 분포, 확률질량함수로 표현

1) 이산균등분포 : 모든 곳에서 값이 일정한 분포

2) 베르노이분포 : 매 시행마다 오직 두 가지의 결과 뿐인 분포

3) 이항분포 : n번의 독립적인 베르누이 시행 통해 성공할 확률 p를 가지는 분포

4) 기하분포 : 처음 성공이 나올 때까지 시도횟수를 확률변수로 가지는 분포

5) 다항분포 : 여러 개의 값을 가질 수 있는 확률 변수들에 대한 분포

6) 포아송분포 : 단위 공간 내에서 발생할 수 있는 사건의 발생 횟수 표현하는 분포

☞ **'베포항항하'**

(2) 연속 확률분포 : 값을 셀 수 없는 분포, 확률밀도함수로 표현

1) 정규분포 : 우리가 일상생활에서 흔히 보는 가우스분포 (Z검정)

2) t분포 : 단일 집단 평균 혹은 두 집단의 평균치 차이의 비교 검정 시 사용 (T검정)

- 데이터 개수가 30개 이상이면 정규성 검정 불필요

3) 카이제곱분포 : 두 집단의 동질성 검정, 혹은 단일 집단 모분산에 대한 검정 (카이제곱 검정)

4) F분포 : 두 집단의 분산의 동일성 검정 시 사용 (F검정)

(3) 확률변수 X의 f(x) 확률분포의 대한 기댓값($E(X)$)

1) 이산적 확률변수 : $E(X) = \sum xf(x)$ 2) 연속적 확률변수 : $E(X) = \int xf(x)$

● 추정

- 표본으로부터 모집단을 추측하는 방법

(1) 점추정 : 모집단이 특정한 값

(2) 구간추정 : 모집단이 특정한 구간 (95%, 99%를 가장 많이 사용)

1) 모집단의 분산을 알고 있는 경우 : $\bar{X} - Z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + Z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$

2) 모집단의 분산을 모르는 경우 : $\bar{X} - t_{\frac{\alpha}{2},n-1}\frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2},n-1}\frac{S}{\sqrt{n}}$ (S : 표본표준편차)

* 자유도가 n-1인 t분포를 이용하여 신뢰구간을 추정

● **가설검정**

- 모집단의 특성에 대한 주장을 가설로 세우고 표본조사로 가설의 채택여부를 판정

(1) 귀무가설(H0) : 일반적으로 생각하는 가설 (차이가 없다)

(2) 대립가설(H1) : 귀무가설을 기각하는 가설, 증명하고자 하는 가설 (차이가 있다, 크다/작다)

(3) 유의수준(α) : 귀무가설이 참일 때 기각하는 1종 오류를 범할 확률의 허용 한계 (일반적 0.05)

(4) 유의확률(p-value) : 귀무가설을 지지하는 정도를 나타내는 확률

검정결과 / 실제	H0가 사실이라고 판정	H0가 거짓이라고 판정
H0가 사실	옳은 결정	1종 오류(α)
H0가 거짓	2종 오류(β)	옳은 결정

● **가설 검정 문제 풀이 방법**

1) 귀무가설 / 대립가설 설정

- '차이가 없다' 혹은 '동일하다' → 귀무가설

2) 양측 혹은 단측검정 확인

- 대립가설의 값이 '같지 않다' → 양측검정 / '값이 크다', '값이 작다' → 단측검정

3) 일표본 혹은 이표본 확인

- 하나의 모집단 → 일표본 / 두개의 모집단 → 이표본

4) 귀무가설 기각 혹은 채택

- p-value < 유의수준(α) → 귀무가설 기각 / p-value > 유의수준(α) → 귀무가설 채택

5) t검정인 경우 – 단일표본, 대응표본, 독립표본 확인

- 모집단에 대한 평균검정 → 단일표본
- 동일 모집단에 대한 평균비교 검정 → 대응표본
- 서로 다른 모집단에 대한 평균비교 검정 → 독립표본

- 두 학교의 학생들의 수학 점수에 대한 t검정

```
> t.test(schoolA,schoolB,conf.level=0.95)

        Welch Two Sample t-test

data:  schoolA and schoolB
t = -0.59758, df = 97.409, p-value = 0.5515
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -10.293157   5.528998
sample estimates:
mean of x mean of y
 61.91373  64.29581
```

1) 귀무가설/대립가설 설정
- '차이가 없다' 혹은 '동일하다' → 귀무가설로 설정
: 두 학교의 성적은 동일하다
2) 양측 혹은 단측검정 확인
- 대립가설의 값이 같지 않다 → 양측검정
3) 일표본 혹은 이표본 확인
- 두개의 모집단 → 이표본
4) 귀무가설 기각 혹은 채택
- p-value : 0.5515 > 유의수준(α) : 0.05 → 귀무가설 채택
5) 단일표본, 대응표본, 독립표본 확인
- 서로 다른 모집단에 대한 평균비교 검정 → 독립표본

● **비모수검정**

(1) 모집단에 대한 아무런 정보 없을 때

(2) 관측 자료가 특정 분포를 따른다고 가정 불가

(3) 부호검정, 순위합검정, 만-휘트니 U검정, 크러스컬-월리스 검정

- 기초 통계분석

● **회귀분석**

(1) 개념 : 독립변수들이 종속변수에 영향을 미치는 파악하는 분석방법

1) 독립변수 : 원인을 나타내는 변수 (x)

2) 종속변수 : 결과를 나타내는 변수 (y)

3) 잔차 : 계산값과 예측값의 차이 (오차 : 모집단 기준, 잔차 : 표본집단 기준)

(2) 회귀계수 추정방법

- 최소제곱법 : 잔차의 제곱합이 최소가 되는 회귀계수와 절편을 구하는 방법

(3) 회귀모형 평가

- R-square : 총 변동 중에서 회귀모형에 의하여 설명되는 변동이 차지하는 비율 (0 ~ 1)

● **회귀분석의 가정**

(1) 선형성 : 종속변수와 독립변수는 선형관계

(2) 등분산성 : 잔차의 분산이 고르게 분포

(3) 정상성(정규성) : 잔차가 정규분포의 특성을 지님

(4) 독립성 : 독립변수들간 상관관계가 없음

- 정규성은 Q-Q plot, 샤피로 윌크 검정, 히스토그램, 왜도와 첨도 활용 확인

● **회귀분석 종류**

(1) 단순회귀 : 1 개의 독립변수와 종속변수의 선형관계

(2) 다중회귀 : 2 개 이상의 독립변수와 종속변수의 선형관계

(3) 다항회귀 : 2 개 이상의 독립변수와 종속변수가 2 차 함수 이상의 관계

(4) 릿지회귀 : L2 규제를 포함하는 회귀 모형

(5) 라쏘회귀 : L1 규제를 포함하는 회귀 모형

● **회귀분석의 분산분석(ANOVA)표**

요인	제곱합	자유도	제곱평균	F비
회귀	SSR = $\sum(\hat{Y}-\bar{Y})^2$	p(회귀계수 수)	$MSR = \frac{SSR}{p}$	$F = \frac{MSR}{MSE}$
잔차	SSE = $\sum(Y-\hat{Y})^2$	n(전체 데이터 수) – p – 1	$MSE = \frac{SSE}{n-p-1}$	
총	SST = SSR + SSE	n - 1		

☞ SST : Sum of Squares Total / SSR : Sum of Squares Regression / SSE : Sum of Squares Error

- ANOVA 검정 : 3 개 이상의 그룹의 평균을 비교하는 검정 (회귀모형의 유의성 분석 시 활용)
- 결정계수(R-Square) = $\frac{SSR}{SST}$ = 1 - $\frac{SSE}{SST}$
- Adjusted R-square = $1-(n-1)\frac{MSE}{SST}$ (다중 회귀에서는 Adjusted R-square 사용)
- 전체 데이터 수 = 자유도 + 1

● **회귀 모형의 검정**

1) 독립변수와 종속변수 설정

2) 회귀계수 값의 추정

3) 모형이 통계적으로 유의미한가 : 모형에 대한 F 통계량, p-value

- 귀무가설 : '모든 회귀계수는 0 이다'

4) 회귀계수들이 유의미한가 : 회귀계수들의 t 통계량, p-value

- 각각의 회귀계수에 대한 귀무가설 : '회귀 계수는 0 이다'

5) 위 1), 2) 모두를 기각하면 해당 모델을 활용

6) 모형이 설명력을 갖는가 : 결정계수(R square) 값

- 종속변수 height / 독립변수 age, no_sibilings

```
Call:
lm(formula = height ~ age + no_siblings, data = ageandheight)

Residuals:
     Min       1Q   Median       3Q      Max
-0.28029 -0.22490 -0.02219  0.14418  0.48350

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 64.95872    0.55752 116.515 1.28e-15 ***
age          0.63516    0.02254  28.180 4.34e-10 ***
no_siblings -0.01137    0.05893  -0.193    0.851
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2693 on 9 degrees of freedom
Multiple R-squared:  0.9888,    Adjusted R-squared:  0.9863
F-statistic: 397.7 on 2 and 9 DF,  p-value: 1.658e-09
```

- 회귀모형 F분포의 P-value(1.658e-09)가 0.05보다 작으므로 모형이 유의미
- age의 p-value(4.34e-10)가 0.05보다 작으므로 회귀계수 유의미
- no_sibilings의 p-value(0.851)가 0.05보다 크므로 제외하고 회귀분석 재수행을 권장
- 위 모형은 다중회귀 모형
- R-square : 0.9888, Adjusted R-square : 0.9863 (모형은 전체 데이터의 98%이상을 설명)
- 회귀 자유도 : 2, 잔차의 자유도 : 9 → 총 2 + 9 +1 = 12개의 데이터를 활용하여 분석
- 모델 회귀 식 : $Y_{height} = 0.63516X_{age} - 0.01137X_{no_sibilings} + 64.95872$

● **최적의 회귀 방정식 탐색 방법**

(1) 전진선택법 : 변수를 하나씩 추가하면서 최적의 회귀방정식을 찾아내는 방법

(2) 후진제거법 : 변수를 하나씩 제거하면서 최적의 회귀방정식을 찾아내는 방법

(3) 단계별 선택법 : 전진선택법 + 후진선택법으로 변수를 추가할 할 때 벌점을 고려

1) AIC (아카이케 정보 기준)

- 편향과 분산이 최적화 되는 지점 탐색, 자료가 많을수록 부정확

2) BIC (베이즈 정보 기준)

- AIC를 보완했지만 AIC보다 큰 패널티를 가지는 단점, 변수가 적은 모델에 적합

☞ AIC와 BIC 모두 작을수록 좋음

- 다변량 분석

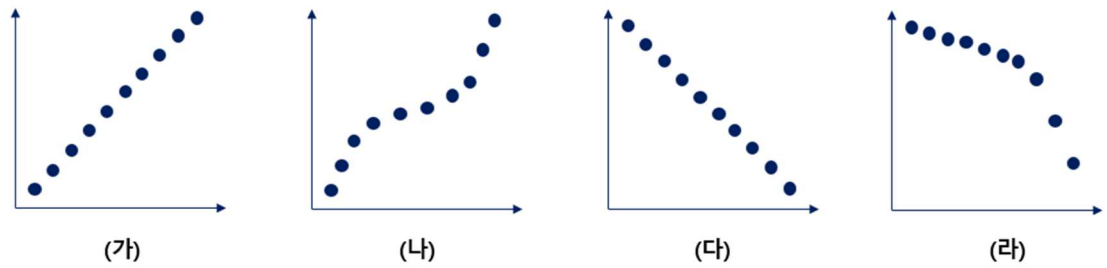
● 상관분석

- 두 변수간의 선형적 관계가 존재하는 파악하는 분석

(1) 종류

1) 피어슨 상관분석 : 양적 척도, 연속형 변수, 선형관계 크기 측정

2) 스피어만 상관분석 : 서열 척도, 순서형 변수, 선형/비선형적 관계 나타냄



(기) 피어슨 계수 = +1, 스피어만 계수 = +1
(나) 피어슨 계수 = +0.8, 스피어만 계수 = +1
(다) 피어슨 계수 = -1, 스피어만 계수 = -1
(라) 피어슨 계수 = -0.8, 스피어만 계수 = -1
☞ 스피어만 계수는 X와 Y가 선형 관계가 아니더라도 1혹은 -1이 될 수 있다.

(2) 다중공선성

- 다중회귀분석에서 설명변수들 사이에 상관관계가 클 때 모델을 불안정하게 만듬
- VIF(분산팽창인수) 값이 10 이상이면 다중공선성 존재한다고 판단

● 다차원 척도법 (MDS : MultiDimensional Scaling)

- 데이터 간 거리 정보의 근접성을 시각화 (2차원 평면이나 3차원 공간에 표현)

(1) 특징 : 데이터 축소 목적, Stress 값이 0에 가까울 수록 좋음, x/y축 해석이 불가

(2) 종류

1) 계량적 MDS : 양적척도 활용

2) 비계량적 MDS : 순서척도 활용

● **주성분 분석 (PCA)**

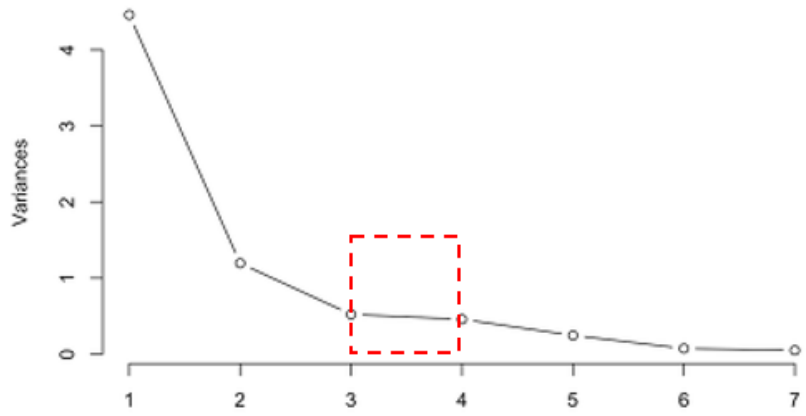
- 상관성 높은 변수들의 선형 결합으로 차원을 축소하여 새로운 변수를 생성
- 자료의 분산이 가장 큰 축이 첫 번째 주성분 - 70 ~ 90%의 설명력을 갖는 수를 결정

```
> result<-prcomp(data,center=T,scale.=T)
> summary(result)
                          PC1    PC2     PC3     PC4     PC5     PC6     PC7
Standard deviation     2.1119 1.0928 0.72181 0.67614 0.49524 0.27010 0.2214
Proportion of Variance 0.6372 0.1706 0.07443 0.06531 0.03504 0.01042 0.0070
Cumulative Proportion  0.6372 0.8078 0.88223 0.94754 0.98258 0.99300 1.0000
```

- center=T, scale.=T : 평균 0, 분산 1
- 첫번째 주성분(PC1)의 분산(0.6372)이 가장 큼
- 두 개의 주성분(PC1, PC2)을 적용하면 전체 데이터의 약 80%를 설명

(1) 스크리플롯(Screeplot)

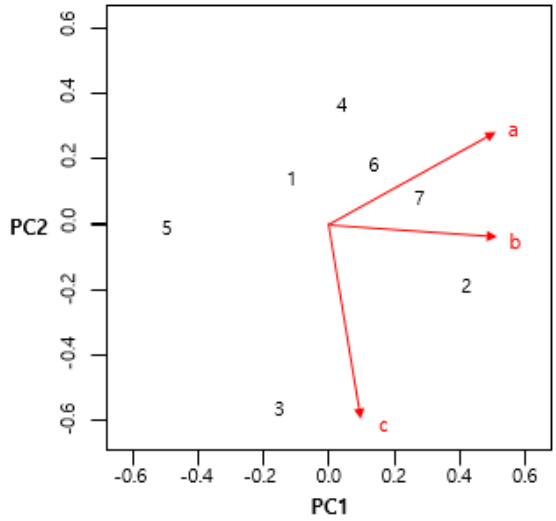
- 주성분의 개수를 선택하는데 도움이 되는 그래프 (x축 주성분 개수, y축 분산변화)
- 수평을 이루기 바로 전 단계 개수로 선택



- 기울기가 3-4 구간에서 완만해지므로 주성분 개수는 2개로 선택

(2) 바이플롯

- 데이터간 유사도를 한번에 볼 수 있는 그래프 (x축 첫번째 주성분, y축 두번째 주성분)
- PC와 평행할수록 해당 PC에 큰 영향
- 화살표의 길이가 길수록 분산이 큼



- a와 b는 상대적으로 축이 가까우므로 상관관계가 높음
- c값이 커질수록 PC1은 증가하고, PC2는 감소
- 데이터 3은 c요소에 가장 큰 영향을 받는 데이터
- 데이터 7은 a와 b에 대하여 영향을 많이 받음
- 데이터 5는 a, b, c에 대하여 영향을 적게 받음
- PC1과는 b > a > c 순으로 영향력이 높음

- 시계열 예측

● 시계열 분석

- 시간의 흐름에 따라 관찰된 자료의 특성을 파악하여 미래를 예측 (주가데이터, 기온데이터)

● 정상성

- 시계열 예측을 위해서는 모든 시점에 일정한 평균과 분산을 가지는 정상성을 만족해야 함
- 정상시계열로 변환 방법
  1) 차분 : 현 시점의 자료를 이전 값으로 빼는 방법
  2) 지수변환, 로그변환

● 백색 잡음

- 시계열 모형의 오차항을 의미하며 원인은 알려져 있지 않음
- 평균이 0 이면 가우시안 백색잡음

● **시계열 모형**

(1) 자기회귀(AR) 모형

- 자기자신의 과거 값이 미래를 결정하는 모형
- 부분자기상관함수(PACF)를 활용하여 p+1 시점 이후 급격 감소하면 AR(p) 모형 선정

(2) 이동평균(MA) 모형

- 이전 백색잡음들의 선형결합으로 표현되는 모형
- 자기상관함수(ACF)를 활용하여 q+1 시차 이후 급격히 감소하면 MA(q) 모형 선정

(3) 자기회귀누적이동평균(ARIMA) 모형

- AR 모형과 MA 모형의 결합
- ARIMA(p, d, q)
  1) p 와 q 는 AR 모형과 MA 모형이 관련 있는 차수
  2) d 는 정상화시에 차분 몇 번 했는지 의미
  3) d = 0 : ARMA 모델 / p = 0 : IMA 모델 / q = 0 : ARI 모델

● **분해시계열**

- 시계열에 영향을 주는 일반적인 요인을 시계열에서 분리해 분석하는 방법

(1) 추세 요인 : 장기적으로 증가, 감소하는 추세

(2) 계절 요인 : 계절과 같이 고정된 주기에 따라 변화

(3) 순환 요인 : 알려지지 않은 주기를 갖고 변화 (경제 전반, 특정 산업)

(4) 불규칙 요인 : 위 3 가지로 설명 불가한 요인

☞ '**추**운 **계절**의 **순환**이 **불규칙**하다.'

3. 정형 데이터 마이닝

- 데이터 마이닝 개요

● **데이터 마이닝**

- 방대한 데이터 속에서 새로운 규칙, 패턴을 찾고 예측을 수행하는 분야

● **데이터 마이닝의 유형**

(1) 지도학습 : 정답이 있는 데이터를 활용

- 인공신경망, 의사결정트리, 회귀분석, 로지스틱회귀

☞ '**인공의사회귀**'

(2) 비지도학습 : 정답이 없는 데이터들 사이의 규칙을 파악

- 군집분석, SOM, 차원축소, 연관분석

● **과대적합과 과소적합**

(1) 과대적합 : 모델이 지나치게 데이터를 학습하여 매우 복잡해진 모델

(2) 과소적합 : 데이터를 충분히 설명하지 못하는 단순한 모델

● **데이터 분할**

- 과대적합과 과소적합을 방지하고, 데이터가 불균형한 문제를 해결하기 위해 사용

(1) 분할된 데이터 셋 종류

1) 훈련용(Training Set) : 모델을 학습하는데 활용 (50%)

2) 검증용(Validation Set) : 모델의 과대,과소 적합을 조정하는데 활용 (30%)

3) 평가용(Test Set) : 모델을 평가하는데 활용 (20%)

(2) 분할된 데이터의 학습 및 검증 방법

1) 홀드아웃 : 훈련용과 평가용 2개의 셋으로 분할

2) K-fold 교차검증 : 데이터를 k개의 집단으로 구분하여 k-1개 학습, 나머지 1개로 평가

3) LOOCV : 1개의 데이터로만 평가 나머지로 학습, 데이터 수가 부족할 때 적용

4) 부트스트래핑 : 복원추출을 활용하여 데이터 셋을 생성, 데이터 부족, 불균형 문제 해소

- 분류분석

● **로지스틱 회귀분석**

- 종속변수가 범주형 데이터를 대상으로 성공과 실패 2개의 집단을 분류하는 문제에 활용

(1) 오즈(Odds)

- Odds = 성공확률(P) / 실패확률(1-P) *성공할 확률과 실패할 확률의 비

(2) 로짓(logit)변환

- 오즈에 자연로그(자연상수 e가 밑)를 취하는 작업

- 독립변수 X가 n증가하면 확률이 e^n 만큼 증가

● **의사결정트리(Decision Tree)**

- 여러 개의 분리 기준으로 최종 분류 값을 찾는 방법

(1) 분류(범주형)에서의 분할 방법

1) CHAID 알고리즘 : 카이제곱 통계량

2) CART 알고리즘 : 지니지수 활용 $(1-\sum P^2)$

3) C4.5/C5.0 알고리즘 : 엔트로피지수 활용 $(-\sum P(\log P))$

(2) 회귀(연속형)에서의 분할 방법

1) CHAID 알고리즘 : ANOVA F통계량

2) CART 알고리즘 : 분산감소량

- 지니지수와 엔트로피지수 계산



- 앞면 확률 = $\frac{3}{5}$, 뒷면 확률 = $\frac{2}{5}$
- 지니지수 : $1-\left(\frac{3}{5}\right)^2-\left(\frac{2}{5}\right)^2=\frac{12}{25}$
- 엔트로피지수 : $-\frac{3}{5}\log\left(\frac{3}{5}\right)-\frac{2}{5}\log\left(\frac{2}{5}\right)$

(2) 학습간 규제

1) 정지규칙

- 분리를 더 이상 수행하지 않고 나무의 성장을 멈춤

2) 가지치기

- 일부 가지를 제거하여 과대적합을 방지

● 앙상블

- 여러 개의 예측 모형들을 조합하는 기법으로 전체적인 분산을 감소시켜 성능 향상이 가능

(1) 보팅(Voting) : 다수결 방식으로 최종 모델을 선택

(2) 배깅(Bagging) : 복원추출에 기반을 둔 붓스트랩을 생성하여 모델을 학습 후 보팅으로 결합

* 복원추출을 무한히 반복할 때 특정 하나의 데이터가 선택되지 않을 확률 : 36.8%

(3) 부스팅(Boosting) : 잘못된 분류 데이터에 큰 가중치를 주는 방법, 이상치에 민감

- 종류 : AdaBoost, GBM, XGBoost, Light GBM

(4) 스태킹(Stacking) : 각각의 모델에서 학습한 예측 결과를 다시 학습

(5) 랜덤포레스트

- 배깅에 의사결정트리를 무작위성으로 주입하는 기법으로 성능이 좋고 이상치에 강한 모델

☞ 보팅, 배깅, 랜덤포레스트는 병렬처리가 가능하며, 부스팅은 병렬처리가 불가

● 인공신경망

- 인간의 뇌 구조를 모방한 퍼셉트론을 활용한 추론모델

(1) 구조

1) 단층 신경망 : 입력층과 출력층으로 구성 (단일 퍼셉트론)

2) 다층 신경망 : 입력층과 출력층 사이에 1개 이상의 은닉층 보유 (다층 퍼셉트론)

- 은닉층 수는 사용자가 직접 설정하는 하이퍼파라미터

(2) 가중치 : 각 퍼셉트론으로의 입력신호 강도 조절

(3) 활성화 함수 : 입력 신호를 출력 신호로 변환, 인공신경망의 선형성을 극복

1) 시그모이드 함수

- 0 ~ 1 사이의 확률 값을 가지며, 로지스틱 회귀 분석과 유사

2) 소프트맥수 함수

- 출력 값이 여러 개로 주어지고 목표 데이터가 다범주인 경우 활용

3) 하이퍼볼릭 탄젠트(Tanh) 함수

- -1 ~ 1 사이 값을 가지며, 시그모이드 함수의 최적화 지연을 해결

4) ReLU 함수

- 기울기 소실문제를 극복, $max(0,x)$

(4) 학습 방법

1) 순전파(피드포워드) : 정보가 전방으로 전달

2) 역전파 알고리즘 : 가중치를 수정하여 오차를 줄임

3) 경사하강법 : 경사의 내리막길로 이동하여 오차가 최소가 되는 최적의 해를 찾는 기법

4) 기울기 소실 문제

- 다수의 은닉층에서 시그모이드 함수 사용 시, 학습이 제대로 되지 않는 문제

● 기타 분류모델

(1) KNN(K-Nearest Neighbors) : 거리기반으로 이웃에 많은 데이터가 포함되어 있는 범주로 분류

(2) 나이브베이즈

- 나이브(독립) + 베이즈 이론을 기반하여, 귀납적인 경험적 추론을 바탕으로 확률 계산

(3) SVM(Support Vector Machine) : 선형/비선형, 분류/회귀 등에서 활용할 수 있는 다목적 모델

- 마진이 최대가 되는 초평면을 찾으며, 커널함수로 데이터의 차원을 높임

● 분류모델 평가지표

(1) 오분류표(혼동행렬)

		실제	
		TRUE	FALSE
예측	TRUE	TRUE POSITIVE (TP)	FALSE POSITIVE (FP)
	FALSE	FALSE NEGATIVE (FN)	TRUE NEGATIVE (TN)

☞ 예측과 실제가 같으면 TRUE, 예측이 TRUE면 POSITIVE

(2) 평가지표

지표	계산식
정밀도(Precision)	$\frac{TP}{TP+FP}$
재현율(Recall)	$\frac{TP}{TP+FN}$
특이도(Specificity)	$\frac{TN}{FP+TN}$
정확도(Accuracy)	$\frac{TP+TN}{TP+FP+FN+TN}$
FP Rate (False Alarm Rate)	$\frac{FP}{FP+TN}$
F-1 Score	$2\times\frac{Precision\cdot recall}{Precision+recall}$
F-β Score	$(1+\beta^2)\times\frac{Precision\cdot recall}{(\beta^2\cdot Precision)+recall}$

- 재현율(Recall)은 민감도(Sensitivity), TP Rate, Hit Rate라고도 함
- F-1 Score는 Precision과 Recall의 조화평균
- Precision과 Recall은 Trade-Off 관계

(3) ROC 커브

- 가로축을 1-특이도(FPR), 세로축을 민감도(TPR)로 두어 시각화한 그래프
- 그래프 면적이 클수록(1에 가까울수록) 모델의 성능이 좋다고 평가 (0.5~1의 면적을 가짐)

(4) 이익도표(Lift chart)

- 임의로 나눈 각 등급별로 반응검출율, 반응률, 리프트 등의 정보를 산출하여 나타내는 도표
- 향상도 곡선 : 이익도표를 시각화한 곡선

- 군집분석

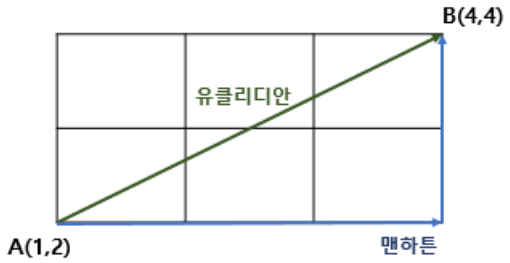
● 군집분석

- 비지도 학습으로 데이터들 간 거리나 유사성을 기준으로 군집을 나누는 분석

● 거리측도

(1) 연속형 변수

- 유클리디안 거리 : 두 점 사이의 직선 거리
- 맨하튼 거리 : 각 변수들의 차이의 단순 합
- 체비셰프 거리 : 변수 거리 차 중 최댓값
- 표준화 거리 : 유클리디안 거리를 표준편차로 나눔
- 민코우스키 거리 : 유클리드, 맨하튼 거리를 일반화한 거리
- 마할라노비스 거리 : 표준화 거리에서 변수의 상관성 고려



- 유클리디안 거리
  : $\sqrt{(4-1)^2+(4-2)^2}=\sqrt{13}$
- 맨하튼 거리
  : $|4-1|+|4-2|=5$
- 체비셰프 거리
  : $\max(|4-1|,|4-2|)=3$

(2) 범주형 변수

- 자카드 유사도(합집합과 교집합의 비율), 코사인 유사도(코사인 각도 활용)

☞ '**맨체**스터 **유**나이티드' '**자코**'

● 실루엣 계수

- 군집분석을 평가하는 지표로서 같은 군집간 가깝고, 다른 군집간 먼 정도를 판단 (-1 ~ 1)

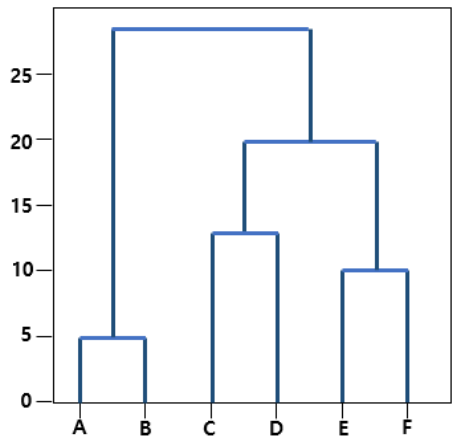
● 계층적 군집분석

(1) 거리측정 방법

1) 최단 연결법(단일 연결법) : 군집간 가장 가까운 데이터
2) 최장 연결법(완전 연결법) : 군집간 가장 먼 데이터
3) 평균 연결법 : 군집의 모든 데이터들의 평균
4) 중심 연결법 : 두 군집의 중심
5) 와드 연결법 : 두 군집의 편차 제곱합이 최소가 되는 위치

(2) 덴드로그램

- 계층적 군집화를 시각적으로 나타내는 Tree모양의 그래프



- 거리를 15에서 나누면 3개의 클러스터, 25에서 나누면 2개의 클러스터로 나눌 수 있음

● **K평균 군집화(K-means Clustering)**

- 비계층적 군집화 방법으로 거리기반

(1) 특징

- 안정된 군집은 보장하나 최적의 보장은 어려움
- 한번 군집에 속한 데이터는 중심점이 변경되면 군집이 변할 수 있음

(2) 과정

1) 군집의 개수 K개 설정 (Elbow Method를 활용 최적의 K 설정)
2) 초기 중심점 설정
3) 데이터들을 가장 가까운 군집에 할당
4) 데이터의 평균으로 중심점 재설정
5) 중심점 위치가 변하지 않을 때까지 3), 4)번 과정 반복

(3) K-medoids 군집화

- K평균 군집화의 이상치에 민감함을 대응하기 위한 군집방법
- 일반적으로 실현된 것이 PAM(Partitioning Around Medoid)

● **DBSCAN**

- 비계층적 군집화 방법으로 밀도기반
- 군집의 개수 K는 지정할 필요 없음
- 노이즈와 이상치에 강함

● **혼합분포군집**

- EM 알고리즘 활용

(1) E-Step

1단계) 초기 파라미터 값 임의 설정
2단계) 파라미터 값 활용하여 기댓값 계산

(2) M-Step

3단계) 기댓값으로부터 확률분포의 파라미터 값 추정
4단계) 2단계부터 반복 수행

● **SOM(자기 조직화 지도)**

- 차원축소와 군집화를 수행하여 고차원 데이터 시각화하는 기법

(1) 구성 : 은닉층 없이 입력층과 출력층으로만 구성

(2) 특징

- 인공신경망과 달리 순전파 방식만 사용

- 완전연결의 형태
- 경쟁층에 표시된 데이터는 다른 노드로 이동 가능
- 입력변수의 위치 관계를 그대로 보존

- 연관분석

● 연관분석

- 항목들간의 조건-결과로 이루어지는 패턴을 발견하는 기법 (장바구니 분석)

(1) 특징

- 결과가 단순하고 분명 (IF~THEN~)
- 품목 수가 증가할수록 계산량이 기하급수적으로 증가
- Apriori 알고리즘(최소 지지도 활용 빈발항목집합 추출)을 활용 후, 연관분석을 수행

(2) 순차패턴 : 연관분석에 시간 개념을 추가하여 품목과 시간에 대한 규칙 찾는 기법

● 연관분석의 지표

(1) 지지도 : $\frac{N(A \cap B)}{전체} = P(A \cap B)$

- A와 B 두 품목이 동시에 포함된 거래 비율

(2) 신뢰도 : $\frac{P(A \cap B)}{P(A)}$

- A 품목이 거래 될 때 B품목도 거래될 확률 (조건부 확률)

(3) 향상도 : $\frac{P(A \cap B)}{P(A)P(B)}$

- A 품목과 B 품목의 상관성

(향상도 > 1 : 양의상관관계, 향상도 = 1 : 상관없음, 향상도 < 1 : 음의상관관계)

☞ '지신향'

- 맥주를 구매할 때 치킨을 구매하는 확률에 대한 신뢰도와 향상도

거래코드	품목	거래 횟수
1	맥주	10
2	치킨	20
3	햄버거	70
4	맥주, 치킨	20
5	맥주, 햄버거	30
6	치킨, 햄버거	10
7	맥주, 치킨, 햄버거	40

(1) 맥주의 구매 확률 = (10 + 20 + 30 + 40) / 200 = 0.5
(2) 치킨의 구매 확률 = (20 + 20 + 10 + 40) / 200 = 0.45
(3) 맥주와 치킨의 지지도 = (20 + 40) / 200 = 0.3
(4) 맥주 → 치킨의 신뢰도 = 0.3 / 0.5 = 0.6
(5) 맥주와 치킨의 향상도 = 0.3 / (0.5 * 0.45) = 1.33
- 맥주와 치킨의 향상도가 1보다 크므로 양의 상관관계를 가짐